

AI 使用说明

一、基本说明

本次数据分析与可视化报告是围绕着福州二手房数据开展的，根据 `ershoufang_list.csv` 中的福州二手房挂牌数据，完成数据读取、数据质量检查、字段清洗、描述性统计、可视化分析和综合结论整理。

在完成数据分析报告的过程中，我有选择地使用了 AI 工具作为辅助。AI 的作用主要集中在代码语法理解、报错排查、函数用法确认、图表表达优化和文字表述润色等环节，未让 AI 直接替代我完成数据判断和分析结论。最终报告中的分析思路、变量选择、图表解读和主要结论，均是在我理解数据含义和运行结果后自行判断、修改和取舍得到的。

二、使用的AI工具

1. ChatGPT 和 豆包

主要用于辅助解释 Python / pandas / seaborn 相关问题，帮助我理解部分函数参数、排查代码报错，并对部分文字表达进行润色。

2. Notebook 自带运行环境与报错信息

我主要根据 Jupyter Notebook 的实际运行结果、输出表格和图表来检查分析是否合理。AI 只作为解释和优化工具，不作为最终判断依据。

三、使用 AI 的具体环节

本次对 AI 的使用比较克制，主要集中在以下几个环节：

1. 解释代码报错和语法问题

在编写数据清洗代码时，部分字段包含单位、空格和中文字符，例如 面积 中的“m²”、总价 中的“万”、均价 中的“元/m²”、户型 中的“室、厅、卫”、楼层 中的“中层(共31层)”等。我使用 AI 帮助理解正则表达式、`apply()`、`DataFrame` 拆分赋值等写法，以便把文本字段转换成可以统计分析的数值变量。

2. 查询 pandas 函数和matplotlib, seaborn 的部分函数用法

在进行描述性统计和交叉分析时，我查询

了 `groupby()`、`agg()`、`pivot_table()`、`crosstab()`、`corr(method='spearman')` 等函数的用法。AI

主要帮助我确认这些函数适合解决什么问题，例如如何按市区统计房源量和价格中位数，如何制作“面积段 × 总价段”的交叉表，以及为什么在非正态、右偏数据中可以使用 Spearman 相关系数。

在图表绘制方面，我也查询了 matplotlib 和 seaborn 中部分函数及参数的用法，例如柱状图、箱线图、散点图、热力图的绘制方式，以及如何设置图表标题、坐标轴标签、图例、字体大小和图表布局。AI 的作用主要是帮助我理解函数参数和优化代码表达，使图表展示更加清晰，但具体选择哪些变量进行分析、图表结果如何解释，以及最终结论如何归纳，仍然是我根据 notebook 中的数据结果自行判断完成的。

3. 优化图表代码和图形可读性

在绘制图表时，我参考AI的建议对部分图形表达进行了优化，例如：

- 横向条形图用于展示各市区房源量，便于比较供给集中度
- 气泡图同时展示市区均价中位数、总价中位数和房源量
- 直方图加入均值线和中位数线，用来说明均价分布的右偏特征
- 散点图在展示时使用 1%—99% 分位数控制坐标范围，以避免极端值压缩主体样本
- 热力图用于呈现面积段与总价段之间的市场层级关系

这些优化主要是为了提高图表的可读性和解释性，图表所表达的结论仍然来自我对数据结果的理解。

4. 借助AI梳理分析步骤和报告结构

在完成报告的主要代码和图表后，我使用 AI 辅助梳理了整体分析步骤，帮助我检查从数据读取、数据清洗、描述性统计、可视化分析到结论总结的顺序是否清楚。由于本次分析涉及房源总价、单价、面积、城区、户型等多个变量，如果直接写结论容易显得比较零散，因此我借助 AI 帮助整理报告结构，使不同部分之间的衔接更加自然。

例如，在撰写分析说明时，我会询问 AI 如何把“先观察整体价格分布，再比较不同城区差异，最后分析面积和价格关系”这样的思路表达得更清晰。AI主要提供的是结构上的建议，比如哪些内容适合放在前面作为总体概况，哪些内容适合放在后面作为进一步分析。

对于AI给出的结构建议，我并没有全部照搬，而是结合报告 中实际完成的代码和图表进行取舍。最终报告中的分析顺序和重点，仍然按照我自己对福州二手房数据的理解进行安排。

5. 整理文字表达

在报告写作部分，我使用 AI 辅助检查部分句子的逻辑顺序和表达方式，使摘要、图表解读、综合讨论和不足部分更加连贯。例如，我参考 AI 的表达建议，将结论整理为“供给集中、价格分层、中心区溢价、主流面积段突出”等较清晰的概括性表述。

但是，AI 只帮助我优化语言表达，我没有直接照搬未经检查的结论。对于每个结论，我都会回到报告中的表格、图表和统计结果进行核对。

四、主要提问内容和提示词

我向 AI 提问的内容主要集中在以下几类：

1. 代码理解类

- 如何从包含单位的字符串中提取数值？
- 如何用正则表达式从“3 室 2 厅 2 卫”中拆分室、厅、卫？
- 如何从“中层(共31层)”中提取楼层位置和总楼层数？

2. pandas 用法类

- `groupby().agg()` 如何同时统计房源量、中位数和均值？
- `pivot_table()` 和 `crosstab()` 分别适合什么分析场景？
- 如何计算不同市区的房源占比？
- 为什么房价数据中位数往往比均值更稳健？

3. 可视化优化类

- 如何让中文图表正常显示？
- 如何在条形图上添加数值标签？
- 如何用气泡图同时表达房源量和价格水平？
- 当散点图受极端值影响时，如何只调整展示范围而不删除数据？

4. 文字表达类

- 如何更清楚地解释“均价分布右偏”？
- 如何说明“房龄越新不一定越贵”？
- 如何把区域价格差异、面积总价关系和市场层级写成更连贯的结论？

这些提问主要是围绕我已经确定的分析任务展开，而不是让 AI 替我重新设计整篇数据分析与可视化报告。

五、对AI输出的检查、修改或取舍

为了避免过度依赖AI，我对AI的建议进行了以下检查和修改：

1. 检查代码是否真正适用于本数据

AI给出的代码示例通常是通用写法，我会根据本次数据字段进行调整。例如，本数据中的字段名称是中文字段，如 面积、总价、均价、户型、楼层、时间 等，因此我没有直接照搬示例代码，而是结合实际字段名称重新修改。

2. 检查清洗结果是否可靠

在文本提取后，我专门比较了 面积_m²、 总价_万元、 均价_元每m² 与数据中原有数值列之间的差异。结果显示最大绝对差异为 0，说明提取结果可靠。只有在确认清洗结果正确后，我才继续进行统计分析。

3. 对异常值没有简单删除

AI在处理异常值时可能会建议删除极端值，但我没有直接采用这种做法。因为二手房数据中的大面积、高总价、高单价房源可能是真实存在的别墅、大平层或核心区稀缺房源，具有市场含义。因此我在统计分析中保留这些记录，只在部分散点图展示时使用分位数范围改善可读性。

4. 根据数据结果修改文字结论

AI生成的文字有时会比较笼统，我会根据报告中的实际统计结果进行修改。例如：

- 有效价格分析样本为 11830 条；
- 晋安和仓山合计约占有效样本七成；
- 鼓楼均价中位数最高；
- 均价均值高于中位数，说明分布右偏；
- 2年内房源均价中位数较低，说明“越新越贵”并不一定成立。

这些具体判断均来自报告中python的运行结果，而不是直接使用AI的概括。

5. 舍弃过度复杂的建议

AI有时会建议使用更复杂的模型或方法，例如回归模型、机器学习预测、空间建模等。但考虑到本课程重点是数据分析与可视化，而且当前数据缺少经纬度、地铁距离、学区、成交价等关键变量，我没有采用过度复杂的方法，而是选择了更适合本数据和本人理解能力的描述统计、分组比较、交叉分析和可视化分析。

六、根据数据自行判断得到的分析结论

以下结论主要是我根据数据清洗结果、统计表格和图表自行判断得到的：

1. 福州二手房挂牌供给具有明显区域集中性。

通过各市区房源量统计和图 1 可以看出，晋安和仓山房源量明显高于其他区域，二者合计约占有效样本七成，因此我判断福州二手房挂牌供给存在明显集中性。

2. 中心城区存在较明显的价格优势。

通过不同市区均价中位数比较和图 2 可以看出，鼓楼、晋安、台江等区域价格较高，而罗源、永泰等外围区域价格较低，因此我判断福州二手房价格存在空间梯度。

3. 挂牌均价呈右偏分布，中位数比均值更适合描述典型水平。

通过图 3 和描述性统计结果可以看出，均价均值高于中位数，并且存在少量高单价房源，因此我认为使用中位数进行价格比较更稳健。

4. 面积会影响总价，但不能单独解释单价差异。

通过面积与总价散点图以及 Spearman 相关分析，我判断面积与总价之间存在较强正相关。但同等面积房源之间的总价差异较大，说明区位、单价、品质和市场定位也会影响价格。

5. 房龄与价格之间不是简单的“越新越贵”关系。

通过不同房龄组的均价分布可以看出，2 年内房源的均价中位数并不是最高。这说明较新房源可能更多分布在外围新区，而中心区较老房源可能因配套成熟而保持较高价格。

6. 福州二手房市场具有明显层级结构。

通过面积段与总价段交叉表和热力图可以看出，60—120m²、100—300 万元是样本中的主流区间；150m²以上房源总价明显上移，更偏改善或高端改善市场。因此我判断福州二手房市场由刚需、改善和高端改善等不同层级共同构成。

7. 楼层对价格的影响小于区域因素。

从低层、中层、高层的均价中位数看，三者差距不大。相比之下，不同市区之间的价格差异更明显，因此我认为在本数据中区域因素比楼层因素更重要。

七、总体反思

本次数据分析与可视化报告中，AI对我起到的是辅助作用，主要帮助我更快理解函数用法、优化部分图表代码和整理文字表达。我是在自己已有分析思路的基础上，在对数据字段含义、清洗逻辑、统计结果和图表结论的理解上，有针对性地询问具体问题，再结合实际数据结果进行检查和修改。这样既能提高完成效率，也能保证自己能够解释关键代码和主要结论。